


EAI-Lab5

學號：NM6131051 姓名：張芷晴

一、在公開的 Gradio 介面網址上，上傳圖片之結果：

共測試六種圖片，分別為：deer、bird、truck、horse、truck、cat

圖片來源皆來自 google 搜尋，大小選擇圖示。



二、說明使用 compare_fp32_int8 function 中，你觀察到 FP32 與 INT 8 有什麼差別，需附上相關證據。

1. 效能差異：


根據第一部分所測試的六張圖片，發現 INT8 的模型比 FP32 的模型慢大約 3~4 倍，但理論上 INT8 應該要比 FP32 快？有在討論區看到其他同學也有相同的疑問，看了助教的回答後，我嘗試換用 colab 去跑，發現同樣的 car 變成 INT18(14.33ms)比 FP32(26.09)快。所以這部分的確有可能是我自己所使用的硬體不支援 INT8 加速。

下表為 FP32 和 INT8 效能差異：

| | FP32 | Int8 |
|-------|-------|-------|
| Deer | 4.76 | 15.53 |
| Bird | 3.99 | 18.26 |
| Truck | 4.76 | 15.55 |
| Horse | 23.43 | 31.59 |
| Car | 3.98 | 18.31 |
| Cat | 4.65 | 15.41 |

2. 準確度差異：

這次我用三張不同的狗狗照片去測試，發現 FP32 的準確率較高，INT8 較低，這部分滿合理的，因為他是量化過後的模型，自然沒那麼精確。



三、對於本次 lab 的心得與建議

我覺得這次的 Lab 滿有趣的，第一次使用 Gradio，感覺之後也可以把它用在其他地方，或是期末專案。還有討論區也是一個很不錯的設置，常常遇到問題的時候，會先在上面看有沒有其他同學有相同的疑問，可以省去滿多自己盲目找尋解答的時間。